

SRV-AI · РАБОЧЕЕ МЕСТО ИИ

Корпоративный веб-интерфейс к локальной языковой модели: чат, заметки, календарь и база знаний в едином окне — целиком в закрытом контуре предприятия.

- ЛОКАЛЬНО, БЕЗ ИНТЕРНЕТА
- АУТЕНТИФИКАЦИЯ И РОЛИ
- ФИЛЬТР ПДН
- АУДИТ ДЕЙСТВИЙ
- LLAMA.CPP · QWEN

ЗАЧЕМ

ЕДИНОЕ РАБОЧЕЕ МЕСТО ОТДЕЛА


Штатный веб-интерфейс Llama.cpp не подходил по требованиям ИБ: нет аутентификации, разграничения пользователей и журналирования. Вместо него — собственный интерфейс, где сотрудники работают с моделью, а данные не покидают изолированный контур. Модель умеет вести заметки и календарь пользователя по запросу на естественном языке.

01

ЕДИНЫЙ ВХОД И РОЛИ

Локальные логин и пароль. Самостоятельной регистрации нет — учётные записи заводит администратор.

- Сессии в httpOnly-cookie, TTL 12 часов, ограничение попыток входа по IP
- Две роли: администратор и пользователь
- Первый администратор создаётся CLI-командой
- На странице входа — памятка: гостайну не вводить, ответы модели проверять специалистом



02

ЧАТ С ЛОКАЛЬНОЙ МОДЕЛЬЮ

Потоковый ответ из llama.cpp. История чатов приватна для каждого пользователя.


- Режим «Размышления» — reasoning в сворачиваемом блоке, в следующий запрос не уходит; тумблер thinking-режима у каждого чата свой
- Markdown с таблицами и кодом, формулы LaTeX (KaTeX, локально), переключатель «рендер ↔ исходник», копирование ответа
- Живые индикаторы: курсор у строки генерации, шиммер по «Размышлениям» с выпиской последней мысли, спиннер у чата в списке
- Статистика под ответом: токены, скорость (счётчики сервера), время ответа и заполнение контекста в % от заданного лимита; живой счётчик тикает во время генерации
- Действия под каждым сообщением: продолжить, регенерировать (у ответа), редактировать, удалить (у запроса); sticky-скролл не мешает листать историю во время генерации

03

МОДЕЛЬ РАБОТАЕТ С ЗАМЕТКАМИ И КАЛЕНДАРЁМ

Tool calling на естественном языке: «создай заметку», «что у меня на неделе», «перенеси совещание на четверг».

- Серверный агентный цикл, до 6 шагов за ответ
- Инструменты исполняются от имени пользователя — чужие личные данные недоступны
- Плашки «создана заметка ...» по факту выполнения
- Удаление и перезапись — только по подтверждению в интерфейсе



04

ФИЛЬТР ПЕРСОНАЛЬНЫХ ДАННЫХ

Персональные данные маскируются ДО отправки в модель и ДО записи в историю чатов.

- Регулярные выражения: телефоны, e-mail, СНИЛС, ИНН, паспорт, карты (проверка по Луну), счета
- NER для ФИО (Natasha / Slovnnet) — офлайн, на CPU, без обращений в сеть
- Белый список для нормативки — чтобы не маскировать подписантов документов
- В модель уходит уже очищенный текст; исходные значения в неё не попадают

05

ЗАМЕТКИ

Личные и общие заметки. Поиск по подстроке и тэгам, редактор с предпросмотром markdown.

- Полный CRUD; тот же REST API используют инструменты модели
- В общих заметках фиксируется «изменено: кем и когда»
- Экспорт заметки в PDF со всеми формулами (KaTeX) — печать браузера, офлайн

07

ДОКУМЕНТЫ В ЧАТ

txt, md, csv, docx, xlsx, pdf, png, jpg — до 15 МБ. Разбор на сервере, файлы не хранятся.

- Текст извлекается на бэкенде (таблицы csv/xlsx → markdown)
- PDF: тумблер в чате «как картинку» (все страницы через mmproj — модель видит вёрстку, чертежи, формулы) или «как текст» (дёшево)
- Картинки и PDF-сканы распознаёт сама мультимодальная модель (mmproj)
- В чате документ — сворачиваемый блок; извлечённый текст проходит фильтр ПДн, проверка MIME, защита от zip-бомб

09

ПРОФИЛЬ И ЭРГНОМИКА

Смена пароля, размер шрифта в три ступени, кликабельные примеры на пустом экране.

- Обратная связь 👍/👎 с комментарием у каждого ответа
- Выгрузка оценок в JSONL — задел под дообучение (LoRA)

06

КАЛЕНДАРЬ

Личные и общие события. Вид «Месяц» и «Список ближайших», создание и перенос в модальном окне.

- Часовой пояс Europe/Moscow, хранение в ISO 8601
- Общие события визуально помечены
- Тот же REST API используют инструменты модели

08

РЕЖИМЫ И СВОЙ СИСТЕМНЫЙ ПРОМПТ

Специализации (Механообработка, Сварка, Литьё...) наполняет администратор. Пользователь выбирает режим или пишет свой промпт.

- Библиотека промптов под задачи отдела редактируется в администрировании
- Свой системный промпт действует в рамках конкретного чата и имеет приоритет над режимом

АДМИНИСТРИРОВАНИЕ

Пользователи, специализации, примеры запросов, метрики и журнал аудита — в одном разделе для админа.

- Метрики: число запросов, успех/неуспех, токены/с, срабатывания ПДн по типам — без содержания запросов
- Журнал аудита: входы (в т.ч. неудачные), действия с пользователями, вызовы инструментов, удаления
- Пользователи: создание, блокировка, сброс пароля, удаление с каскадом данных (с двойным подтверждением)
- Выгрузка обратной связи в JSONL

СВЕТЛАЯ И ТЁМНАЯ ТЕМЫ

Переключатель в профиле: светлая, тёмная или «как в системе». Выбор хранится на пользователе и следует за аккаунтом на любом устройстве.

- Тёмная палитра в фирменном стиле — графит и красный акцент
- Применяется до отрисовки, без «вспышки»; работает и на экране входа
- Формулы, таблицы, код, поля ввода — читаемы в обеих темах

МЕЛОЧИ, ИЗ КОТОРЫХ СКЛАДЫВАЕТСЯ УДОБСТВО

То, что делает ежедневную работу с моделью на CPU предсказуемой и приятной.

■ ПАРАЛЛЕЛЬНЫЕ ЧАТЫ

Генерация не обрывается при переходе в другой чат; в списке — индикатор идущего инференса.

■ ЧЕСТНАЯ ОЧЕРЕДЬ

Модель на CPU обрабатывает запросы последовательно; в интерфейсе — статус «В очереди: N».

■ ПРОДОЛЖЕНИЕ ОТВЕТА

Кнопка «Продолжить» дописывает оборванный длинный ответ в то же сообщение.

■ СКОРОСТЬ КАК В LLAMA.CPP

Токены/с берутся из счётчиков сервера (usage / timings), а не оцениваются приблизительно.

■ КОПИРОВАНИЕ И MARKDOWN

Скопировать весь ответ или переключить его между рендером и исходным markdown.

■ API-КЛЮЧ ПО ЖЕЛАНИЮ

Bearer к Llama.cpp с --api-key или стороннему провайдеру; безвреден, если сервер ключ не требует.

■ ФОРМУЛЫ LATEX

KaTeX локально (без CDN): $\$...\$$ и $\$\$...\$ \$$ в ответах рендерятся, включая кириллические индексы.

■ ТУМБЛЕРЫ НА ЧАТ

«Заметки/Календарь» и «Размышления» — своё состояние у каждого чата, переживает перезагрузку.

■ ПРИВАТНОСТЬ ИСТОРИИ

Шифрование БД на диске (SQLCipher) и автоочистка сообщений старше N дней — по флагам в .env.

■ ТЁМНАЯ ТЕМА

Светлая / тёмная / как в системе; выбор на аккаунте, без «вспышки» при загрузке.

■ ВРЕМЯ ОТВЕТА

Под ответом — сколько заняла генерация от «Отправить» до конца; живой таймер во время генерации.

■ ЗАМЕТКА В PDF

Любую заметку — в PDF со всеми формулами, одной кнопкой, офлайн.

ЧЕСТНОСТЬ МОДЕЛИ

Системный промпт: не выдумывать факты и термины, при незнании — прямо говорить.

ИНФРАСТРУКТУРА

LLAMA.CPP + QWEN ПОД КАПОТОМ

Веб-интерфейс работает поверх развёрнутых на сервере сервисов: языковая модель и база знаний. Наружу открыт только UI.

МОДЕЛЬ

Qwen3.6-35B-A3B (GGUF, квант UD-Q8_K_XL) на **llama.cpp** (CPU-сервер). OpenAI-совместимый API на 127.0.0.1:8000: --jinja (шаблон чата с tool calling), --mmproj (vision: картинки и PDF-сканы), --reasoning-format deepseek (thinking-режим), --no-webui — штатный интерфейс отключён, работает только наш UI. Thinking отключается на лету через chat_template_kwargs — тумблер «Размышления» в чате.

- UI — 0.0.0.0:8001, единственный порт наружу; вход только по паролю
- llama.cpp — 127.0.0.1:8000, доступ в обход UI невозможен
- Эмбединги bge-m3 — локальный порт, использует LightRAG
- LightRAG — база знаний отдела, URL и ключ в .env
- Счётчики usage/timings сервера — честные токены/с, время ответа и % контекста (лимит LLM_CONTEXT_SIZE)
- systemd --user + linger: автозапуск после ребута без root

ДОКУМЕНТАЦИЯ

КАК ЭТО УСТРОЕНО

Без пафоса: архитектура, стек, данные, безопасность и развёртывание — коротко и по делу.

АРХИТЕКТУРА

Один процесс Python (FastAPI + uvicorn) раздаёт статику и проксирует запросы. Фронтенд — vanilla ES-модули без этапа сборки. Хранилище — файл SQLite (WAL). Обращения наружу — только к модели и базе знаний.

```
[Браузер] —HTTP→ [FastAPI :8080]
├─ /api/chat —SSE→ llama.cpp :8000 (/v1/chat/completions)
├─ /api/rag —→ LightRAG (URL из конфига)
├─ SQLite (users, chats, messages, notes, events, audit_log, ...)
└─ статика (index.html, css, js, шрифты)
```

СТЕК И ЗАВИСИМОСТИ

- **Backend:** Python 3.10+, FastAPI, uvicorn, httpx (SSE), aiosqlite, bcrypt
- **Документы:** python-docx, openpyxl, pypdf, Pillow; системно — poppler-utils (pdftoppm)
- **Фильтр ПДн:** natasha, slovnet, navec (NER ФИО, офлайн)
- **Frontend:** статические HTML/CSS/JS без сборки; локальные шрифты и вендоры
- Минимум зависимостей — код обзорим для аудита ИБ

СХЕМА ДАННЫХ (SQLITE)

ТАБЛИЦА	НАЗНАЧЕНИЕ
users, sessions	учётные записи, роли, активные сессии
chats, messages	чаты и история (content, reasoning, вложения, статистика)
notes, events	заметки и события — личные / общие
specializations, chat_examples	режимы чата и примеры запросов
feedback	оценки ответов (задел под датасет)
audit_log	факты действий: кто, что, когда — без содержания

РАЗВЁРТЫВАНИЕ

- Онлайн и офлайн (air-gap): каталог `wheels/`, всё локально
- systemd-сервис (системный или пользовательский, без root), автозапуск
- Бэкап: снимок SQLite + .env; резервное копирование по расписанию
- Пошаговые инструкции — в каталоге `docs/` (быстрый тест, стабильный запуск, подключение LightRAG)

БЕЗОПАСНОСТЬ (ИБ)

- Никакого исходящего трафика, кроме адресов модели и базы знаний
- Обязательная аутентификация; параметризованные SQL-запросы
- Экранирование HTML при рендере markdown (защита от XSS)
- CSRF: SameSite=Lax + проверка Origin на мутациях; заголовки X-Frame-Options=DENY, CSP default-src 'self'
- Фильтр ПДн; в аудит и логи содержание запросов и пароли не пишутся
- Модели (:8000/:8001) закрываются на localhost — прямой доступ в обход UI невозможен
- Приватность истории: чаты изолированы по владельцу (у админа нет доступа к чужим); опционально — шифрование БД на диске (SQLCipher, ключ в .env) и автоочистка сообщений старше N дней

ПРИЁМКА

- Чужие личные заметки и события недоступны ни через UI, ни через API, ни через инструменты модели
- «Создай на завтра совещание и заметку с повесткой» → событие и заметка появляются без ручных действий
- «Что у меня на этой неделе?» → ответ по реальным данным календаря
- При выключенном интернете всё работает после офлайн-установки