

SRV-AI · РАБОЧЕЕ МЕСТО ИИ

Корпоративный веб-интерфейс к локальной языковой модели: чат, заметки, календарь и база знаний в едином окне - целиком в закрытом контуре предприятия.

- ЛОКАЛЬНО, БЕЗ ИНТЕРНЕТА
- АУТЕНТИФИКАЦИЯ И РОЛИ
- ФИЛЬТР ПДН
- АУДИТ ДЕЙСТВИЙ
- LLAMA.CPP + QWEN

ЗАЧЕМ

ЕДИНОЕ РАБОЧЕЕ МЕСТО ОТДЕЛА


Штатный веб-интерфейс llama.cpp не подходил по требованиям ИБ: нет аутентификации, разграничения пользователей и журналирования. Вместо него - собственный интерфейс, где сотрудники работают с моделью, а данные не покидают изолированный контур. Модель умеет вести заметки и календарь пользователя по запросу на естественном языке.

01

ЕДИНЫЙ ВХОД И РОЛИ

Локальные логин и пароль. Самостоятельной регистрации нет - учётные записи заводит администратор.

- Сессии в httpOnly-cookie, TTL 12 часов, ограничение попыток входа по IP
- Две роли: администратор и пользователь
- Первый администратор создаётся CLI-командой
- На странице входа - памятка: гостайну не вводить, ответы модели проверять специалистам



02

ЧАТ С ЛОКАЛЬНОЙ МОДЕЛЬЮ

Потоковый ответ из llama.cpp. История чатов приватна для каждого пользователя.

- Режим «Размышления» - reasoning в сворачиваемом блоке, в следующий запрос не уходит; тумблер thinking-режима у каждого чата свой

- Markdown с таблицами и кодом, формулы LaTeX (KaTeX, локально), переключатель «рендер ↔ исходник», копирование ответа

- Живые индикаторы: курсор у строки генерации, шиммер по «Размышлениям» с выпиской последней мысли, спиннер у чата в списке

- Статистика под ответом: токены, скорость (счётчики сервера), время ответа и заполнение контекста в % от заданного лимита; живой счётчик тикает во время генерации


- Действия под каждым сообщением: продолжить, регенерировать (у ответа), редактировать, удалить (у запроса); sticky-скролл не мешает листать историю во время генерации

03

МОДЕЛЬ РАБОТАЕТ С ЗАМЕТКАМИ И КАЛЕНДАРЁМ

Tool calling на естественном языке: «создай заметку», «что у меня на неделе», «перенеси совещание на четверг».

- Серверный агентный цикл, до 6 шагов за ответ
- Инструменты исполняются от имени пользователя - чужие личные данные недоступны
- Плашки «создана заметка ...» по факту выполнения
- Удаление и перезапись - только по подтверждению в интерфейсе



04

ФИЛЬТР ПЕРСОНАЛЬНЫХ ДАННЫХ

Персональные данные маскируются ДО отправки в модель и ДО записи в историю чатов.

- Регулярные выражения: телефоны, e-mail, СНИЛС, ИНН, паспорт, карты (проверка по Луну), счета
- ФИО - по правилам (отчества, инициалы, словарь имён), без внешних моделей и сети
- Белый список для нормативки - чтобы не маскировать подписантов документов
- В модель уходит уже очищенный текст; исходные значения в ней не попадают

05

ЗАМЕТКИ

Личные и общие заметки. Поиск по подстроке и тэгам, редактор с предпросмотром markdown.

- Полный CRUD; тот же REST API используют инструменты модели
- В общих заметках фиксируется «изменено: кем и когда»
- Экспорт заметки в PDF со всеми формулами (KaTeX) - печать браузера, офлайн

06

КАЛЕНДАРЬ

Личные и общие события. Вид «Месяц» и «Список ближайших», создание и перенос в модальном окне.

- Часовой пояс Europe/Moscow, хранение в ISO 8601
- Общие события визуально помечены
- Тот же REST API используют инструменты модели

07

ДОКУМЕНТЫ В ЧАТ

txt, md, csv, docx, xlsx, pdf, png, jpg - до 15 Мб. Разбор на сервере, файлы не хранятся.

- Текст извлекается на бэкенде (таблицы csv/xlsx → markdown)
- PDF: тумблер в чате «как картинку» (все страницы через tmprgo) - модель видит вёрстку, чертежи, формулы) или «как текст» (дёшево)
- Картинки и PDF-сканы распознаёт сама мультимодальная модель (tmprgo)
- В чате документ - сворачиваемый блок; извлечённый текст проходит фильтр ПДн, проверка MIME, защита от zip-бомб

08

РЕЖИМЫ И СВОЙ СИСТЕМНЫЙ ПРОМПТ

Специализации (Механообработка, Сварка, Литьё...) наполняет администратор. Пользователь выбирает режим или пишет свой промпт.

- Библиотека промптов под задачи отдела редактируется в администрировании
- Свой системный промпт действует в рамках конкретного чата и имеет приоритет над режимом

09

ПРОФИЛЬ И ЭРГОНОМИКА

Смена пароля, размер шрифта в три ступени, кликабельные примеры на пустом экране.

- Обратная связь 👍/👎 с комментарием у каждого ответа
- Выгрузка оценок в JSONL - задел под дообучение (LoRA)

10

АДМИНИСТРИРОВАНИЕ

Пользователи, специализации, примеры запросов, метрики и журнал аудита - в одном разделе для админа.

- Метрики: число запросов, успех/неуспех, токены/с, срабатывания ПДн по типам - без содержания запросов
- Журнал аудита: входы (в т.ч. неудачные), действия с пользователями, вызовы инструментов, удаления
- Пользователи: создание, блокировка, сброс пароля, удаление с каскадом данных (с двойным подтверждением)
- Выгрузка обратной связи в JSONL

11

СВЕТЛАЯ И ТЁМНАЯ ТЕМЫ

Переключатель в профиле: светлая, тёмная или «как в системе». Выбор хранится на пользователе и следует за аккаунтом на любом устройстве.

- Тёмная палитра в фирменном стиле - графит и красный акцент
- Светлая / тёмная / как в системе: выбор на аккаунте, без «всплывши»; работает и на экране входа
- Формулы, таблицы, код, поля ввода - читаемы в обеих темах

ЭРГОНОМИКА

МЕЛОЧИ, ИЗ КОТОРЫХ СКЛАДЫВАЕТСЯ УДОБСТВО

То, что делает ежедневную работу с моделью на CPU предсказуемой и приятной.

- ПАРАЛЛЕЛЬНЫЕ ЧАТЫ**
Генерация не обрывается при переходе в другой чат; в списке - индикатор идущего инференса.
- СКОРОСТЬ КАК В LLAMA.CPP**
Токены/с берутся из счётчиков сервера (usage / timings), а не оцениваются приблизительно.
- ФОРМУЛЫ LATEX**
KaTeX локально (без CDN): $\$...\$$ и $\$\$...\$\$$ в ответах рендерятся, включая кириллические индексы.
- ТЁМНАЯ ТЕМА**
Светлая / тёмная / как в системе: выбор на аккаунте, без «всплывши» при загрузке.
- ЧЕСТНОСТЬ МОДЕЛИ**
Системный промпт: не выдумывать факты и термины, при незнании - прямо говорить.
- ЧЕСТНАЯ ОЧЕРЕДЬ**
Модель на CPU обрабатывает запросы последовательно; в интерфейсе - статус «В очереди: N».
- КОПИРОВАНИЕ И MARKDOWN**
Скопировать весь ответ или переключить его между рендером и исходным markdown.
- ТУМБЛЕРЫ НА ЧАТ**
«Заметки/Календарь» и «Размышления» - своё состояние у каждого чата, переживает перезагрузку.
- ВРЕМЯ ОТВЕТА**
Под ответом - сколько заняла генерация от «Отправить» до конца; живой таймер во время генерации.
- ПРОДОЛЖЕНИЕ ОТВЕТА**
Кнопка «Продолжить» дописывает оборванный длинный ответ в то же сообщение.
- АПИ-КЛЮЧ ПО ЖЕЛАНИЮ**
Внедрит llama.cpp с api-key или стороннему провайдеру; безвреден, если сервер ключ не требует.
- ПРИВАТНОСТЬ ИСТОРИИ**
Шифрование БД на диске (SQLCipher) и автоочистка сообщений старше N дней - по флагам в .env.
- ЗАМЕТКА В PDF**
Любую заметку - в PDF со всеми формулами, одной кнопкой, офлайн.

ИНФРАСТРУКТУРА

LLAMA.CPP + QWEN ПОД КАПОТОМ

Веб-интерфейс работает поверх развёрнутых на сервере сервисов: языковая модель и база знаний. Наружу открыт только UI.

- МОДЕЛЬ**
Qwen3.6-35B-A3B (GGUF, квант UD-Q8_K_XL) на **llama.cpp** (CPU-сервер). OpenAI-совместимый API на 127.0.0.1:8000: --jinja (шаблон чата с tool calling), --tmprgo (vision: картинки и PDF-сканы), --reasoning-format deepseek (thinking-режим), --no-webui - штатный интерфейс отключён, работает только наш UI. Thinking отключается на лету через chat_template_kwargs - тумблер «Размышления» в чате.
 - UI - 0.0.0.0:8001, единственный порт наружу; вход только по паролю
 - Эмбеддинги bge-m3 - локальный порт, использует LightRAG
 - Счётчики usage/timings сервера - чистые токены/с, время ответа и % контекста (лимит LLM_CONTEXT_SIZE)
 - llama.cpp - 127.0.0.1:8000, доступ в обход UI невозможен
 - LightRAG - база знаний отдела, URL и ключ в .env
 - systemd --user + linger: автозапуск после ребута без root

ДОКУМЕНТАЦИЯ

КАК ЭТО УСТРОЕНО

Без пафоса: архитектура, стек, данные, безопасность и развёртывание - коротко и по делу.

АРХИТЕКТУРА

Один процесс Python (FastAPI + uvicorn) раздаёт статистику и проксирует запросы. Фронтенд - vanilla ES-модули без этапа сборки. Хранилище - файл SQLite (WAL). Обращения наружу - только к модели и базе знаний.




СХЕМА ДАННЫХ (SQLITE)

ТАБЛИЦА	НАЗНАЧЕНИЕ
users, sessions	учётные записи, роли, активные сессии
chats, messages	чаты и история (content, reasoning, вложения, статистика)
notes, events	заметки и события - личные / общие
specializations, chat_examples	режимы чата и примеры запросов
feedback	оценки ответов (фидбек до датасет)
audit_log	факты действий: кто, что, когда - без содержания

РАЗВЁРТЫВАНИЕ

- Онлайн и офлайн (air-gap): каталог [wheels/](#), всё локально
- systemd-сервис (системный порт, пользовательский, без root), автозапуск
- Бэкап: снимок SQLite + .env; резервное копирование по расписанию
- Пошаговые инструкции - в каталоге [docs/](#) (быстрый тест, стабильный запуск, подключение LightRAG)

СТЕК И ЗАВИСИМОСТИ

- Backend:** Python 3.10+, FastAPI, uvicorn, httpx (SSE), aiosqlite, brypt
- Документы:** python-docx, openpyxl, pypdf, Pillow, pydubfunt2 (растеризация PDF - без системных пакетов)
- Фильтр ПДн:** регулярки + правила для ФИО в приложениях; заголовки X-Frame-Options=DENY, CSP default-src 'self'
- Frontend:** статические HTML/CSS/JS без сборки; локальные шрифты и вендоры
- Минимум зависимостей - код обзорим для аудита ИБ

БЕЗОПАСНОСТЬ (ИБ)

- Никакого исходящего трафика, кроме адресов модели и базы знаний
- Обязательная аутентификация; параметризованные SQL-запросы
- Экранирование HTML при рендере markdown (защита от XSS)
- CSRF: SameSite=Lax + проверка Origin на мутациях; заголовки X-Frame-Options=DENY, CSP default-src 'self'
- Фильтр ПДн; в аудит и логи содержание запросов и пароли не пишутся
- Модели (:8000/:8001) защищены на localhost - прямой доступ в обход UI невозможен
- Приватность истории: чаты изолированы по владельцу (у админа нет доступа к чужим); опционально - шифрование БД на диске (SQLCipher, ключ в .env) и автоочистка сообщений старше N дней

ПРИЁМКА

- Чужие личные заметки и события недоступны ни через UI, ни через API, ни через инструменты модели
- «Создай на завтра совещание и заметку с повесткой» → событие и заметка появляются без ручных действий
- «Что у меня на этой неделе?» → ответ по реальным данным календаря
- При выключенном интернете всё работает после офлайн-установки