

SRV-AI · РАБОЧЕЕ МЕСТО ИИ

Корпоративный веб-интерфейс к локальной языковой модели: чат, заметки, календарь и база знаний в едином окне — целиком в закрытом контуре предприятия.

ЛОКАЛЬНО, БЕЗ ИНТЕРНЕТА · АУТЕНТИФИКАЦИЯ И РОЛИ · ФИЛЬТР ПДН · АУДИТ ДЕЙСТВИЙ · LLAMA.CPP · QWEN

ЗАЧЕМ

ЕДИНОЕ РАБОЧЕЕ МЕСТО ОТДЕЛА

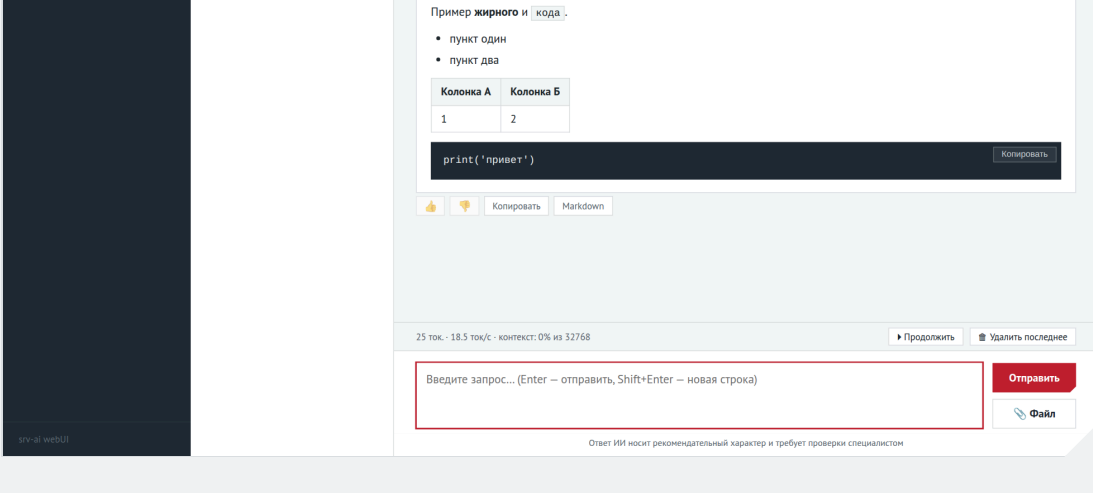
Штатный веб-интерфейс llama.cpp не подходил по требованиям ИБ: нет аутентификации, разграничения пользователей и журналирования. Вместо него — собственный интерфейс, где сотрудники работают с моделью, а данные не покидают изолированный контур. Модель умеет вести заметки и календарь пользователя по запросу на естественном языке.

01

ЕДИНЫЙ ВХОД И РОЛИ

Локальные логин и пароль. Самостоятельная регистрации нет — учётные записи заводит администратор.

- Сессии в httpOnly-cookie, TTL 12 часов, ограничение попыток входа по IP
- Две роли: администратор и пользователь
- Первый администратор создаётся CLI-командой
- На странице входа — памятка: гостайну не вводить, ответы модели проверять специалистом




02

ЧАТ С ЛОКАЛЬНОЙ МОДЕЛЬЮ

Потоковый ответ из llama.cpp. История чатов приватна для каждого пользователя.

- Режим «Размышления» — reasoning в сворачиваемом блоке, в следующий запрос не уходит
- Markdown с таблицами и кодом, переключатель «рендер => исходник», копирование всего ответа
- Панель статистики: токены, скорость (счётчики сервера, как в web UI llama.cpp), заполнение контекста
- Остановка и продолжение генерации, удаление сообщений

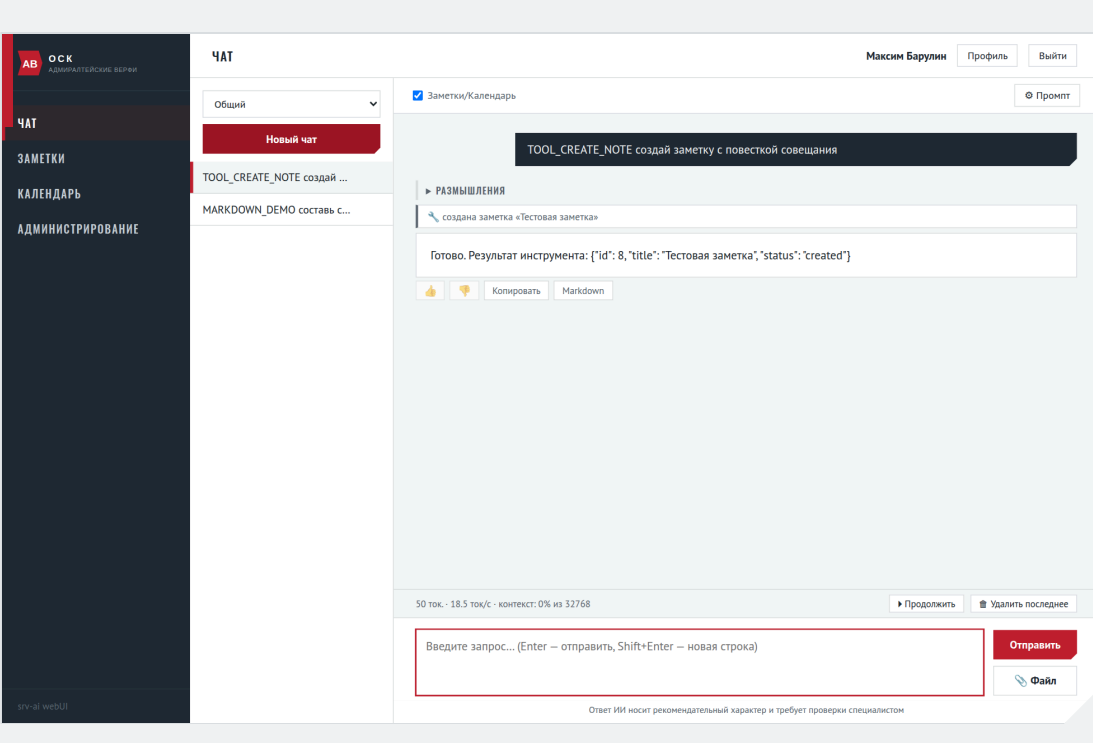
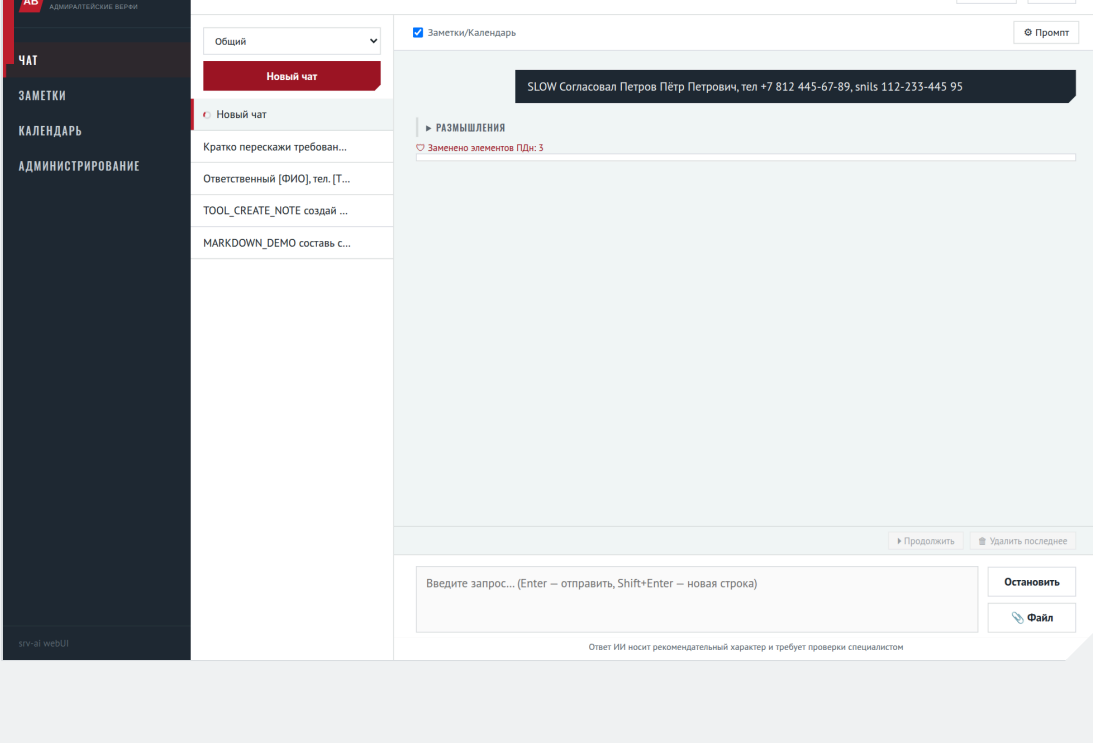


03

МОДЕЛЬ РАБОТАЕТ С ЗАМЕТКАМИ И КАЛЕНДАРЁМ

Tool calling на естественном языке: «создай заметку», «что у меня на неделе», «перенеси совещание на четверг».

- Серверный агентный цикл, до 6 шагов за ответ
- Инструменты исполняются от имени пользователя — чужие личные данные недоступны
- Плашки «создана заметка ...» по факту выполнения
- Удаление и перезапись — только по подтверждению в интерфейсе



04

ФИЛЬТР ПЕРСОНАЛЬНЫХ ДАННЫХ

Персональные данные маскируются ДО отправки в модель и ДО записи в историю чатов.



- Регулярные выражения: телефоны, e-mail, СНИЛС, ИНН, паспорт, карты (проверка по Луну), счета
- NER для ФИО (Natasha / Slovnets) — офлайн, на CPU, без обращений в сеть
- Белый список для нормативки — чтобы не маскировать подписантов документов
- В модель уходит уже очищенный текст; исходные значения в неё не попадают

05

ЗАМЕТКИ

Личные и общие заметки. Поиск по подстроке и тэгам, редактор с предпросмотром markdown.

- Полный CRUD; тот же REST API используют инструменты модели
- В общих заметках фиксируется «изменено: кем и когда»



06

КАЛЕНДАРЬ

Личные и общие события. Вид «Месяц» и «Список ближайших», создание и перенос в модальном окне.

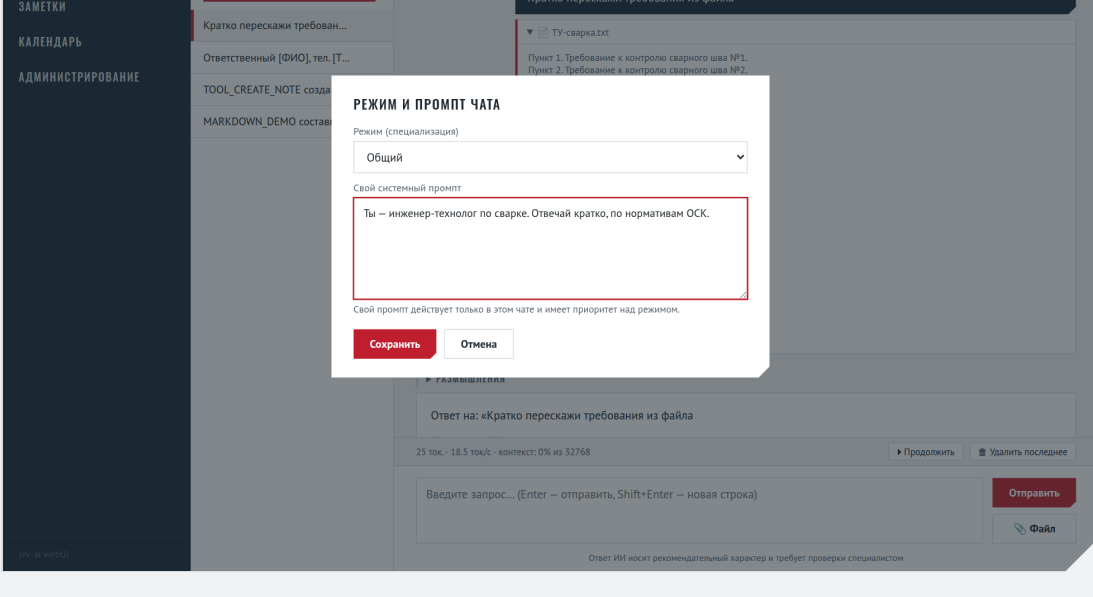
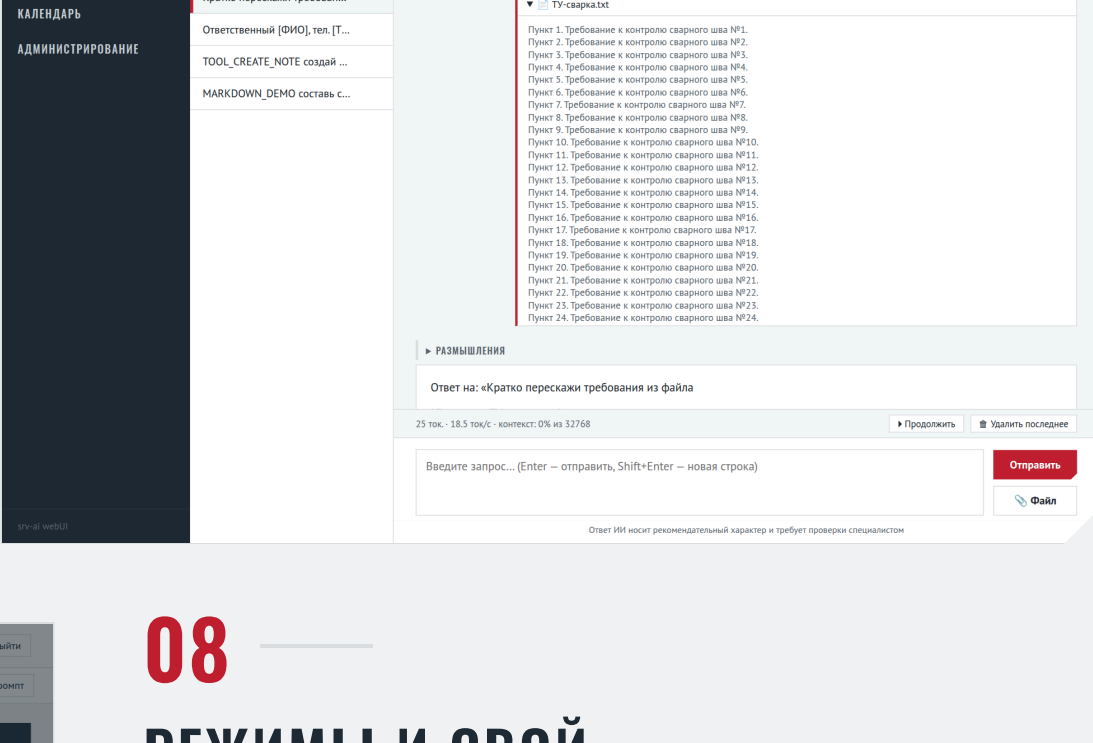
- Часовой пояс Europe/Moscow, хранение в ISO 8601
- Общие события визуально помечены
- Тот же REST API используют инструменты модели

07

ДОКУМЕНТЫ В ЧАТ

txt, md, csv, docx, xlsx, pdf, png, jpg — до 15 Мб. Разбор на сервере, файлы не хранятся.

- Текст извлекается на бэкенде (таблицы csv/xlsx → markdown)
- Картинки и PDF-сканы распознаёт сама мультимодальная модель (mlproq)
- В чате документ — сворачиваемый блок, а не «стена» текста
- Извлечённый текст тоже проходит фильтр ПДн: проверка MIME, защита от zip-бомб




08

РЕЖИМЫ И СВОЙ СИСТЕМНЫЙ ПРОМПТ

Специализации (Механообработка, Сварка, Литьё...) наполняет администратор. Пользователь выбирает режим или пишет свой промпт.

- Библиотека промптов под задачи отдела редактируется в администрировании
- Свой системный промпт действует в рамках конкретного чата и имеет приоритет над режимом




09

ПРОФИЛЬ И ЭРГНОМИКА

Смена пароля, размер шрифта в три ступени, кликабельные примеры на пустом экране.

- Обратная связь 🙌/👍 с комментарием у каждого ответа
- Выгрузка оценок в JSONL — задел под дообучение (LoRA)



10

АДМИНИСТРИРОВАНИЕ

Пользователи, специализации, примеры запросов, метрики и журнал аудита — в одном разделе для админа.

- Метрики: число запросов, успех/неуспех, токены/с, срабатывания ПДн по типам — без содержания запросов
- Журнал аудита: входы (в т.ч. неудачные), действия с пользователями, вызовы инструментов, удаления
- Выгрузка обратной связи в JSONL

ЭРГНОМИКА

МЕЛОЧИ, ИЗ КОТОРЫХ СКЛАДЫВАЕТСЯ УДОБСТВО

То, что делает ежедневную работу с моделью на CPU предсказуемой и приятной.

- ПАРАЛЛЕЛЬНЫЕ ЧАТЫ**
Генерация не обрывается при переходе в другой чат: в списке — индикатор идущего инференса.
- ЧЕСТНАЯ ОЧЕРЕДЬ**
Модель на CPU обрабатывает запросы последовательно: в интерфейсе — статус «В очереди: N».
- ПРОДОЛЖЕНИЕ ОТВЕТА**
Кнопка «Продолжить» дописывает обрванный длинный ответ в то же сообщение.
- СКОРОСТЬ КАК В LLAMA.CPP**
Токены с берутся из счётчиков сервера (usage / tpm3), а не оцениваются приближённо.
- КОПИРОВАНИЕ И MARKDOWN**
Скопировать весь ответ или переключить его между рендером и исходным markdown.
- API-КЛЮЧ ПО ЖЕЛАНИЮ**
Всего в llama.cpp c --api-key или стороннему провайдеру, безвредно, если сервер ключ не требует.

ИНФРАСТРУКТУРА

LLAMA.CPP + QWEN ПОД КАПОТОМ

Веб-интерфейс работает поверх уже развёрнутых сервисов моделей. Раздел заполняется по материалам их развёртывания.

ОТДЕЛЬНАЯ ТЕМА	
Сборка и запуск llama.cpp, параметры Qwen, эмбединги, база знаний. Ориентир по портам и режимам:	
— llama.cpp: OpenAI-совместимый API, порт 8000, ключи --jinja и --mlproq (vision)	— Модель Qwen в thinking-режиме (reasoning-format deepseek)
— Эмбединги (bge-m3), порт 8001 — использует база знаний	— LightRAG — база знаний, подключается по URL из конфига
— Штатный web UI llama.cpp отключён (--no-webui)	— Доступ к моделям — только с localhost, в обход UI невозможен

ДОКУМЕНТАЦИЯ

КАК ЭТО УСТРОЕНО

Без пафоса: архитектура, стек, данные, безопасность и развёртывание — коротко и по делу.

АРХИТЕКТУРА

Один процесс Python (FastAPI + uvicorn) раздаёт статику и проксирует запросы. Фронтенд — vanilla ES-модули без этапа сборки. Хранилище — файл SQLite (WAL). Обращения наружу — только к модели и базе знаний.

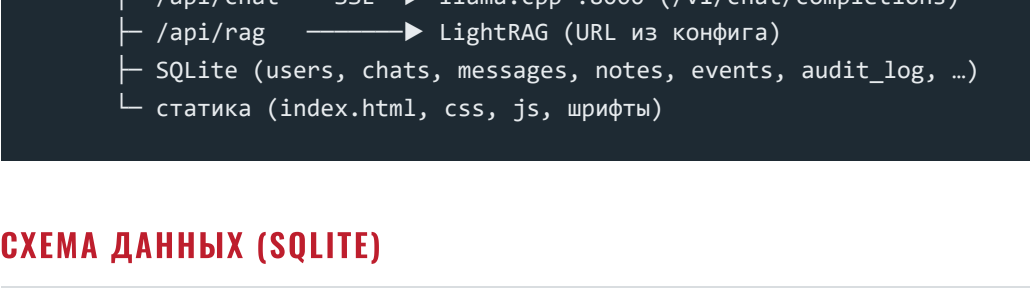


СХЕМА ДАННЫХ (SQLITE)

ТАБЛИЦА	НАЗНАЧЕНИЕ
users, sessions	учётные записи, роли, активные сессии
chats, messages	чаты и история (content, reasoning, вложения, статистика)
notes, events	заметки и события — личные / общие
specializations, chat_examples	режимы чата и примеры запросов
feedback	оценки ответов (задел под датасет)
audit_log	факты действий: кто, что, когда — без содержания

РАЗВЁРТЫВАНИЕ

- Онлайн и офлайн (air-gap): каталог [wheels](#), всё локально
- systemd-сервис (системный или пользовательский, без root), автозапуск
- База: снимок SQLite + .env; резервное копирование по расписанию
- Пошаговые инструкции — в каталоге [docs](#) (быстрый тест, стабильный запуск, подключение LightRAG)

СТЕК И ЗАВИСИМОСТИ

- Backend:** Python 3.10+, FastAPI, uvicorn, httpx (SSE), asyncio, bcrypt
- Документы:** python-docx, openpyxl, pypdf, Pillow; системно — poppler-utils (pdf2opm)
- Фильтр ПДн:** natasha, slovnets, naves (NER ФИО, офлайн)
- Frontend:** статические HTML/CSS/JS без сборки; локальные шрифты и венторы
- Минимум зависимости — код обзорим для аудита ИБ

БЕЗОПАСНОСТЬ (ИБ)

- Никакого исходящего трафика, кроме адресов модели и базы знаний
- Обязательная аутентификация; параметризованные SQL-запросы
- Экранирование HTML при рендере markdown (защита от XSS)
- CSRF: SameSite=Lax + проверка Origin на мутациях; заголовки X-Frame-Options=DENY, CSP default-src 'self'
- Фильтр ПДн: в аудит и логи содержание запросов и пароли не пишется
- Модели (8000/8001) закрываются на localhost — прямой доступ в обход UI невозможен

ПРИЁМКА

- Чужие личные заметки и события недоступны ни через UI, ни через API, ни через инструменты модели
- «Создай на завтра совещание и заметку с повесткой» — событие и заметка появляются без ручных действий
- «Что у меня на этой неделе?» — ответ по реальным данным календаря
- При выключенном интернете всё работает после офлайн-установки